

TRƯỜNG ĐẠI HỌC FPT TP.HCM

BỘ MÔN TRÍ TUỆ NHÂN TẠO

BÁO CÁO ĐỒ ÁN MÔN HỌC ADY201m

Tích hợp Đặc trưng Không gian và Thuật toán XGBoost trong
Bài toán Dự đoán Giá Bất động sản

Sinh viên thực hiện: Nguyễn Võ Tiến Đạt

Môn: ADY201m (AI)

Giảng viên hướng dẫn:

TP. Hồ Chí Minh, 2026

Mục lục

1	Giới thiệu (Introduction)	2
2	Dữ liệu và Phương pháp (Methodology)	2
2.1	Nguồn dữ liệu (Data Source)	2
2.2	Trích xuất dữ liệu bằng SQL (Data Extraction)	2
2.3	Kỹ nghệ Không gian (Geospatial Feature Engineering)	2
3	Kết quả Thực nghiệm (Experimental Results)	3
3.1	Huấn luyện và Đánh giá (Training & Evaluation)	3
4	Phân tích Lỗi và Yếu tố Con người (Human Delta & Data Bias)	3
5	Triển khai Ứng dụng (Web Deployment)	3
6	Kết luận (Conclusion)	4

Tóm tắt nội dung

Dự án này xây dựng một hệ thống dữ liệu hoàn chỉnh (Data Pipeline) nhằm dự đoán giá bất động sản. Khác với các phương pháp truyền thống chỉ dựa trên đặc trưng vật lý, nghiên cứu này lượng hóa yếu tố vị trí địa lý thông qua công thức Haversine. Dữ liệu trích xuất từ Ames Housing Dataset qua hệ thống SQLite in-memory, sau đó được huấn luyện qua 5 mô hình học máy. Kết quả cho thấy XGBoost là mô hình tối ưu nhất ($R^2 = 88.0\%$). Hệ thống cuối cùng được triển khai thành một Web Dashboard tương tác. Dự án cũng chỉ ra hiện tượng "Data Bias" đặc thù của quy hoạch đô thị Mỹ, nhấn mạnh vai trò của kiến thức con người (Human Delta) khi phát triển AI.

1 Giới thiệu (Introduction)

Định giá bất động sản là một bài toán kinh điển trong lĩnh vực Học máy. Trong thực tế, giá trị của một căn nhà phụ thuộc rất lớn vào vị trí địa lý. Tuy nhiên, nhiều dự án cơ bản lại vô tình bỏ qua các đặc trưng không gian (Spatial Features). Trong khuôn khổ môn học ADY201m, đồ án này kết hợp ngôn ngữ truy vấn (SQL), Kỹ nghệ Đặc trưng (Feature Engineering) và các thuật toán Machine Learning để xây dựng một giải pháp định giá toàn diện, đồng thời đưa vào triển khai thực tế thông qua nền tảng Streamlit.

2 Dữ liệu và Phương pháp (Methodology)

2.1 Nguồn dữ liệu (Data Source)

Dữ liệu sử dụng trong nghiên cứu là tập **Ames Housing Dataset**, được trích xuất từ nền tảng Kaggle [1]. Tập dữ liệu này được biên soạn bởi Giáo sư Dean De Cock (Đại học Truman State) nhằm thay thế cho tập Boston Housing cũ. Tập dữ liệu bao gồm 79 biến mô tả chi tiết mọi khía cạnh của các căn nhà dân cư tại Ames, Iowa (Mỹ) trong giai đoạn 2006 đến 2010 [2].

2.2 Trích xuất dữ liệu bằng SQL (Data Extraction)

Nhằm mô phỏng môi trường làm việc chuyên nghiệp, hệ thống không đọc trực tiếp file CSV mà khởi tạo một cơ sở dữ liệu ảo trên RAM (*SQLite In-memory*). Điều này cho phép sử dụng SQL để lọc các giá trị ngoại lai (outliers), loại bỏ dữ liệu rỗng và chỉ giữ lại 5 trường dữ liệu trọng tâm: *OverallQual*, *GrLivArea*, *GarageCars*, *TotalBsmtSF*, *Neighborhood*.

2.3 Kỹ nghệ Không gian (Geospatial Feature Engineering)

Vị trí được lượng hóa bằng cách tính khoảng cách vật lý từ khu dân cư (Neighborhood) đến vùng lõi thương mại của thành phố Ames. Vì Trái Đất là hình cầu, định lý Pytago sẽ tạo ra sai số. Dự án áp dụng **Công thức Haversine** để tính khoảng cách cung tròn bề mặt [3]:

$$d = 2r \arcsin \left(\sqrt{\sin^2 \left(\frac{\Delta\phi}{2} \right) + \cos \phi_1 \cos \phi_2 \sin^2 \left(\frac{\Delta\lambda}{2} \right)} \right) \quad (1)$$

Trong đó: $r = 6371$ km (bán kính Trái Đất); ϕ là Vĩ độ; λ là Kinh độ.

3 Kết quả Thực nghiệm (Experimental Results)

3.1 Huấn luyện và Đánh giá (Training & Evaluation)

Dữ liệu được chia theo tỷ lệ 80/20 và chuẩn hóa bằng `StandardScaler`. Năm thuật toán đã được triển khai để tìm ra mô hình tối ưu. Kết quả trên tập kiểm thử (Test set) được thể hiện tại Bảng 1.

Bảng 1: Hiệu suất của 5 mô hình Học máy

Mô hình (Algorithm)	MAE (USD)	RMSE	R^2 Score
Linear Regression	\$25,509	39,997	0.7914
Decision Tree	\$25,766	38,256	0.8092
Random Forest	\$19,345	30,020	0.8825
Gradient Boosting	\$18,894	28,081	0.8972
XGBoost	\$19,261	30,342	0.8800

Dù Gradient Boosting có điểm R^2 cao nhất (89.7%), **XGBoost** (88.0%) vẫn được chọn làm lõi cho hệ thống triển khai vì tính tối ưu về tốc độ, xử lý ngoại lệ tốt và độ ổn định cao trên môi trường Production.

4 Phân tích Lỗi và Yếu tố Con người (Human Delta & Data Bias)

Khi phân tích sâu vào trọng số của mô hình, một nghịch lý lộ diện: **Khoảng cách đến trung tâm càng xa, mô hình dự đoán giá càng cao.**

Tại các đô thị ở Việt Nam, nhà ở lõi trung tâm luôn đắt đỏ nhất. Tuy nhiên, tập dữ liệu thu thập tại **Ames, Iowa (Mỹ)**. Quy hoạch đô thị Mỹ mang đậm văn hóa ngoại ô (Suburban). Người dân ưu chuộng các căn nhà xa trung tâm để có diện tích lớn, sân vườn rộng và yên tĩnh. Ngược lại, nhà trung tâm thường cũ và chật hẹp hơn.

Đây là minh chứng kinh điển cho khái niệm **Thiên kiến Dữ liệu (Data Bias)**. Trí tuệ nhân tạo (AI) chỉ tìm ra quy luật thống kê mà không thấu hiểu bối cảnh văn hóa. Việc này đòi hỏi kỹ sư dữ liệu (Human Delta) phải giám sát chặt chẽ, không thể áp dụng mù quáng (blind deployment) một mô hình của Mỹ vào thị trường Việt Nam.

5 Triển khai Ứng dụng (Web Deployment)

Mô hình XGBoost và công cụ chuẩn hóa được lưu trữ dưới dạng file nhị phân (.pkl) qua thư viện Joblib. Giao diện trực quan được xây dựng bằng **Streamlit**, cho phép người dùng nhập thông số diện tích, chất lượng, khoảng cách và trả về định giá bằng cả USD và VND.

6 Kết luận (Conclusion)

Đồ án đã thiết lập thành công một quy trình Data Pipeline khép kín: từ trích xuất dữ liệu, kỹ nghệ đặc trưng không gian, huấn luyện mô hình XGBoost, đến triển khai Dashboard tương tác. Trọng tâm cốt lõi của nghiên cứu không chỉ nằm ở mã nguồn hay độ chính xác 88% của thuật toán, mà còn ở tư duy phân tích hệ thống và năng lực nhận diện thiên kiến văn hóa trong Dữ liệu lớn.

Tài liệu

- [1] Kaggle, *House Prices - Advanced Regression Techniques*. [Trực tuyến]. Nguồn: <https://www.kaggle.com/c/house-prices-advanced-regression-techniques>.
- [2] Dean De Cock, *Ames, Iowa: Alternative to the Boston Housing Data as an End of Semester Regression Project*, Journal of Statistics Education, Vol 19, 2011.
- [3] R. W. Sinnott, *Virtues of the Haversine*, Sky and Telescope, vol. 68, no. 2, 159, 1984.
- [4] Tianqi Chen and Carlos Guestrin, *XGBoost: A Scalable Tree Boosting System*, Proceedings of the 22nd ACM SIGKDD International Conference, 2016.